MAKİNE ÖĞRENMESİ EĞİTİMİ

Denetimli ve denetimsiz öğrenme

Dün iki aileyi tanıttık. Bugün ikisini de **içinden** görüyoruz
ve denetimsiz tarafta kendi ellerimizle bir segmentasyon kuruyoruz.

GÜNÜN DÖRT BÖLÜMÜ • 6 SAAT

1 · Denetimli öğrenme derinlemesine
2 · Denetimsiz öğrenme ve kümeleme
3 · Uygulama: müşteri segmentasyonu
4 · Hangisini ne zaman seçmeli

GÜNÜN SONUNDA

· Etiketin nereden geldiğini sorgulayabileceksiniz
· k-ortalamalar ile kümeleme kurabileceksiniz
· Kümeleri iş diline çevirebileceksiniz
· Hangi aileyi seçeceğinize karar verebileceksiniz

DÜN NEREDE KALDIK

Dört kavram, bir çalışan akış

Dün öğrendiğimiz	Tek cümlesi	Bugün ne oluyor
Kural vs öğrenme	Sonucu verir, kuralı alırsınız	Aynı mantık, iki aile için ayrı ayrı
Denetimli / denetimsiz	Cevap veride yazılı mı?	Günün ana konusu
Eğitim-test ayrımı	Görmediği veriyle sınayın	Denetimsizde bu kural işlemiyor — neden?
Aşırı / eksik öğrenme	İki sayıyı yan yana koyun	Kümelemede karşılığı: k seçimi

DÜNÜN AKIŞI HÂLÂ GEÇERLİ

Veri → model → tahmin → değerlendirme.
Bugün denetimsiz tarafta **üçüncü ve dördüncü adım** değişiyor; ilk ikisi aynı.

DÜN AÇIK KALAN SORULAR

İlk on dakika sizin: dün akşam aklınıza takılan ne varsa şimdi sorun.

DÜNÜN EN ÖNEMLİ CÜMLESİ — BUGÜN DE GEÇERLİ

"Bu başarı oranı hangi veride ölçüldü?"
Bugün buna bir ikinci soru ekleyeceğiz: **"bu etiket nereden geldi?"**

GÜNÜN PLANI

Bugün ne var

Bölüm	Süre	Konu	Çıktı
1	dk	Denetimli öğrenme derinlemesine	Etiketin kaynağını sorgulama alışkanlığı
2	dk	Denetimsiz öğrenme ve kümeleme	k-ortalamalar, k seçimi, ölçekleme
3	dk	Uygulama: müşteri segmentasyonu	Kendi notebook'unuzda çalışan bir segmentasyon
4	dk	Hangisini ne zaman seçmeli	Karar rehberi ve sık hatalar listesi

GÜNÜN AĞIRLIK MERKEZİ

Üçüncü bölüm: baştan sona bir **müşteri segmentasyonu**.
Veriyi hazırlayacak, kümeleri bulacak ve onlara iş diliyle isim vereceksiniz.

HAZIR OLUN

Notebook açık, geçen haftaların **sipariş verisi** elinizde olsun.

BUGÜN YAPMAYACAĞIMIZ ŞEY

Algoritmaların matematiğine girmeyeceğiz — o Gün 5'in konusu. Bugün **ne zaman hangisi** ve **sonucu nasıl okuruz** sorularına odaklanıyoruz.

BÖLÜM 1

Denetimli öğrenme, yakından

Dün "hedef sütunu var" dedik ve geçtik. Bugün o sütunun **nereden geldiğini** soruyoruz — çünkü projelerin çoğu orada tıkanıyor, algoritmada değil.

ÜÇ SORU
Etiket nereden geldi, ne kadar güvenilir, kaç tane var?

İKİ GERÇEK ÖRNEK
Bir sınıflandırma, bir regresyon — baştan sona kurulumu.

GÜNÜN YENİ SORUSU

Bu etiket nereden geldi?

Etiket kaynağı	Örnek	Riski
Sistem kaydı	İade yapıldı, fatura ödendi	En güvenilir — ama tanımı kontrol edin
Kullanıcı davranışı	"Spam" işaretledi, ürünü beğendi	Herkes aynı şeyi işaretlemiyor
İnsan eli	Uzman fotoğrafları etiketledi	Pahalı, yavaş, kişiden kişiye değişir
İş kuralı	"90 gün alışveriş yapmadıysa kayıp"	Kuralı siz koydunuz — model onu öğrenir
Başka bir model	Bir model diğerini etiketledi	Hataları miras alır, büyütür

GERÇEK HAYATTAN — "KAYIP MÜŞTERİ" TANIMI

Aboneliği olan bir şirkette kayıp nettir: iptal etti. Perakendede değil — 90 gün mü, 180 gün mü?
Tanımı değiştirdiğinizde **hedef sütunu değişir**, model değişir, sonuçlar karşılaştırılamaz hâle gelir.

İLK İŞ

Etiketin tanımını **yazılı** hâle getirin ve iş tarafına onaylatın. Model kurmadan önce.

ÖZETLE

Model, etikette ne varsa onu öğrenir. **Yanlış tanımlı bir etiket, kusursuz çalışan ve işe yaramayan bir model** üretir.

KİMSE KONUŞMUYOR AMA

Etiket pahalıdır — projenin asıl darboğazı

BEDAVA GELEN ETİKETLER

İşin doğal akışında zaten oluşuyor:
· İade yapıldı mı — sistemde kayıtlı
· Fatura ödendi mi — muhasebede var
· Müşteri iptal etti mi — CRM'de duruyor

Bu problemlerle başlayın.

PARA VE ZAMAN İSTEYEN ETİKETLER

Birinin tek tek bakması gerekiyor:
· Üretim bandındaki parça hatalı mı
· Bu röntgende bulgu var mı
· Bu müşteri yorumu olumlu mu

Önce bütçeyi, sonra modeli planlayın.

GERÇEK HAYATTAN — ÜRETİM BANDI HATA TESPİTİ

Kameradan görüntü almak kolay, günde binlerce kare birikiyor. Ama "bu parça hatalı" etiketini kalite uzmanı koyuyor ve onun zamanı sınırlı. Proje kamerayla değil, **uzmanın takvimiyle** sınırlı.

MALİYETİ DÜŞÜRME YOLLARI

Az sayıda ama **iyi seçilmiş** örnekle başlamak · Birden fazla kişiye aynı örneği verip tutarlılığı ölçmek · Belirsiz örnekleri uzmana yöneltmek

SIRADA

Az etiketle çalışma yöntemleri **bölüm 4'te**.

SINIFLANDIRMA • AYRINTILAR

Model "evet" demiyor, bir olasılık veriyor

ÇIKTI ZİNCİRİ

1. Model bir olasılık üretiyor: 0,78
2. Siz bir eşik koyuyorsunuz: 0,50 mi, 0,30 mu?
3. Eşik etiketi belirliyor: iade olur / olmaz
4. Etiket bir aksiyona bağlanıyor: paketi kontrol et

EŞİK NEREDE DURUYOR

Modelin içinde değil, **onun dışında**.
Değiştirmek için yeniden eğitmek gerekmiyor.

Eşik	Kaç paket işaretlenir	Kaçırılan iade	Boşa kontrol
Düşük (0,20)	Çok	Az	Çok
Orta (0,50)	Dengeli	Orta	Orta
Yüksek (0,80)	Az	Çok	Az

GERÇEK HAYATTAN — AYNI MODEL, İKİ FARKLI EŞİK

Bir bankada sahtecilik modeli iki yerde kullanılıyor: **yüksek eşikle** işlemi anında bloke etmek için, **düşük eşikle** ertesi gün insan incelemesi listesine koymak için.
Tek model, iki eşik, iki iş akışı — çünkü iki aksiyonun maliyeti farklı.

KAÇ SINIF VAR

İkili, çok sınıflı, çok etiketli

Tür	Soru	Örnek	Çıktı
İkili	Olur mu, olmaz mı?	İade edilir mi	Tek olasılık
Çok sınıflı	Hangisi? (bir tane)	Bu talep hangi departmana	Her sınıf için olasılık, toplamı 1
Çok etiketli	Hangileri? (birden fazla)	Bu ürün hangi etiketleri taşıyor	Her etiket için ayrı olasılık

GERÇEK HAYATTAN — ÇAĞRI MERKEZİ YÖNLENDİRME

Gelen talep metninden hangi ekibe gideceğini tahmin etmek: **çok sınıflı**.

Ama bir talep hem faturayı hem teslimatı soruyorsa — artık **çok etiketli** bir problem. Bu ayrımı veriye bakmadan yapamazsınız.

KODDA FARK YOK

scikit-learn hedefteki sınıf sayısına bakıp kendisi ayarlıyor.

Siz aynı fit ve predict'i yazıyorsunuz.

SINIF SAYISI ARTTIKÇA

Her sınıf için **yeterli örnek** gerekiyor. Yirmi departmanınız varsa ve bazısına yılda üç talep geliyorsa, model o sınıfları hiç öğrenmez. Çözüm: az görülen sınıfları birleştirip "diğer" yapmak.

REGRESYON • AYRINTILAR

Sayı tahmininde soru "doğru mu" değil, "ne kadar yakın"

HATA BİR SAYI, YÖNÜ DE VAR

Gerçek 420 adet, tahmin 390 → **30 adet eksik** tahmin.

Sınıflandırmada hata ya var ya yok; regresyonda hatanın **büyüklüğü** ve **yönü** önemli.

YÖN NEDEN ÖNEMLİ

Az sipariş etmek **satış kaybı**, fazla sipariş etmek **depo ve fire**. Maliyetler eşit değil.

GERÇEK HAYATTAN — TAZE ÜRÜN TALEP TAHMİNİ

Bir markette ekmek siparişi: eksik tahmin akşam boş raf, fazla tahmin ertesi gün çöp.
Fire maliyeti satış kaybından düşükse, model **bilerek fazla** tahmin edecek şekilde ayarlanır.
Bu bir teknik ayar değil, iş kararı — ve regresyonda eşiğin karşılığı budur.

TEK TAHMİN YETMEZ

"420 adet" yerine "380–460 arası" demek karar vericiye daha çok şey söylüyor.

SIRADA

Hatanın nasıl ölçüldüğü **Gün 6'da**: ortalama hata, kare hata ve hangisinin ne zaman kullanıldığı.

PROJENİN İLK YARIM SAATİ

Hedefi tanımlarken cevaplanacak beş soru

#	Soru	Yanlış cevabın bedeli
1	Tam olarak neyi tahmin ediyoruz?	Ekip farklı şeyler kurar, sonuçlar karşılaştırılamaz
2	Hangi zaman penceresinde?	30 günlük iade ile 90 günlük iade farklı problemdir
3	Tahmin ne zaman yapılacak?	O ana kadar var olmayan sütunlar özellik sanılır
4	Hangi satırlar kapsamda?	İptal, test, kurumsal siparişler sonucu bozar
5	Tahmini kim, nasıl kullanacak?	Kimsenin kullanmadığı bir model

ÜÇÜNCÜ SORU EN TEHLİKELİSİ

Dünkü iade_kargo_ucreti örneği buradan çıkıyor.

Kural: tahmin anında **var olmayan** hiçbir bilgi özellik olamaz.

ÇIKTI BİR SAYFA

Beş sorunun cevabı yazılı olsun. Proje boyunca başvuracağınız **tek doğru kaynak**.

DÖRDÜNCÜ SORU, SESSİZ BİR TUZAK

Test siparişleri, iptal edilmiş kayıtlar ve toptan müşteriler veride duruyor ve **modelin öğrendiğini bozuyor**.

GERÇEK ÖRNEK 1 • SINIFLANDIRMA

Telekom: hangi abone önümüzdeki ay ayrılır?

Kurulum	Cevap
Hedef	Önümüzdeki 30 gün içinde hattını kapatacak mı (0/1) — iptal kaydından geliyor
Özellikler	Sözleşme süresi, aylık ücret, veri kullanımı, çağrı merkezi temas sayısı, ödeme gecikmesi, tarife değişikliği
Tahmin anı	Her ayın ilk günü, o andaki durumla
Kapsam	Bireysel aboneler; kurumsal hatlar ve yeni başlayanlar hariç
Aksiyon	En yüksek riskli 5.000 aboneye kampanya teklifi

NEDEN KURAL YAZILAMIYOR

Çağrı merkezini arayan abone bazen memnuniyetsiz, bazen sadece bilgi alıyor. Sinyal tek sütunda değil; **sütunların birlikte oluşturduğu desende**.

DİKKAT — KAPSAM

Yeni abone üç ay veri üretmemiş; modele girerse **gürültü** ekler.

AKSİYON SATIRI, MODELİN ŞEKLİNİ BELİRLİYOR

Kampanya bütçesi 5.000 kişilik: eşik aramıyoruz, **olasılığa göre sıralayıp ilk 5.000'i alıyoruz**.

GERÇEK ÖRNEK 2 • REGRESYON

Emlak: bu daire kaç paraya satılır?

Kurulum	Cevap
Hedef	Gerçekleşen satış fiyatı (TL) — tapu/satış kaydından, ilan fiyatından değil
Özellikler	Metrekare, oda sayısı, bina yaşı, kat, semt, ısıtma, otopark, metro mesafesi
Tahmin anı	İlan girilirken — satış bilgisi henüz yok
Kapsam	Konut; ticari, arsa ve miras paylaşımı satışları hariç
Aksiyon	Danışmana fiyat aralığı önermek; aykırı ilanları işaretlemek

İLAN FİYATI DEĞİL, SATIŞ FİYATI

İlan fiyatı satıcının beklentisi, satış fiyatı piyasanın cevabı. İkisi arasında pazarlık var. Hedefi yanlış seçerseniz model **beklentiyi** tahmin eder, fiyatı değil.

ZAMANA GÖRE BÖLME

Fiyatlar zamanla değişiyor: eski satışlarla eğit, **en yeni dönemde** sına.

İKİ ÖRNEK, AYNI BEŞ SORU

Problem ve sektör değişti, **kurulum şablonu aynı kaldı**. Bu şablon sizin kontrol listeniz.

DÜNÜN SORUSUNUN CEVABI

Dengesiz sınıflar: aradığınız şey nadirse

SORUN NE

Sahtecilik, arıza, nadir hastalık — hepsi veride **çok az**.

Model "hiç olmaz" demeyi öğrenirse yüksek doğruluk alır ve **hiçbir işe yaramaz**.

NEDEN OLUYOR

Model hatayı azaltmaya çalışıyor. Çoğunluğa oynamak hatayı azaltmanın **en kolay** yolu.

Çare	Ne yapar	Dikkat
Doğru ölçü seçmek	Doğruluk yerine yakalama oranına bakmak	İlk yapılacak — Gün 6
Sınıf ağırlığı	Nadir sınıfın hatasını modele pahalı göstermek	Tek satır: class_weight
Örnek sayısını dengelemek	Çoğunluktan azaltmak veya azınlığı çoğaltmak	Sadece eğitim kümesinde
Eşiği düşürmek	Daha şüpheci davranmak	Modeli değiştirmiyor

EN SIK YAPILAN HATA

Dengeleme işlemini **bölmeden önce** yapmak. O zaman test kümesi de değişiyor ve ölçtüğünüz başarı gerçek dünyayı temsil etmiyor. Sıra şu: önce böl, sonra sadece eğitimi dengele.

KONTROL NOKTASI 1 • BÖLÜM 1 SONU

Beş soruyu kendi probleminize uygulayın

ŞABLON — 15 DAKİKA, YAZILI

1. Neyi tahmin ediyoruz: _____
2. Hangi zaman penceresi: _____
3. Tahmin anı: _____
4. Kapsam dışı satırlar: _____
5. Kim, nasıl kullanacak: _____
+ Etiket nereden geliyor: _____

ALTINCI SATIR YENİ

Dün bu satır yoktu.

Bugünün kazanımı: etiketin kaynağını **yazmadan** projeye başlamamak.

EN ÇOK TAKILAN SATIR

Dördüncüsü. Kapsamı düşünmek veriyi **gerçekten** tanımayı gerektiriyor.

İKİ KİŞİ ANLATSIN

Dinleyenler **eksik satır** arasın — en iyi geri bildirim o.

Mola, sonra bölüm 2: **etiketin olmadığı** dünyaya geçiyoruz.

BÖLÜM 1 • KISA SINAV

Etiket ve kurulum üzerine beş soru

1

"Kayıp müşteri" tanımını 90 günden 180 güne çıkardınız. Modeli yeniden eğitmek yeter mi?

2

Emlak modelinde hedef olarak ilan fiyatını kullanmak neyi tahmin eden bir model üretir?

3

Arıza verinizin %0,4'ü arızalı. Önce hangi çareye başvurursunuz, neden?

4

İki kalite uzmanı aynı 100 parçayı etiketledi, 70'inde anlaştı. Bu bilgi size ne söylüyor?

5 • EN ZORU

Yönetim "müşteri memnuniyetini tahmin eden bir model" istiyor. Veride memnuniyet sütunu yok.
Ne yapar, ne sorarsınız?

BÖLÜM 1 • CEVAPLAR

Etiket ve kurulum üzerine beş soru

1 • YETMEZ

Hedef sütunu **yeniden üretilmeli** — kimin kayıp sayıldığı değişti, sınıf dağılımı da. Eski ve yeni başarı rakamı karşılaştırılamaz: farklı şeyi tahmin ediyorlar. Tanımı sürüm gibi ele alın.

2 • SATICI BEKLENTİSİ

Piyasa fiyatını değil. "Benzer daireler ne fiyata **ilana giriyor**" der, "ne paraya satılır" demez — arada pazarlık marjı var. Hedefin kolay bulunanı ile doğrusu farklı olabilir.

3 • ÖNCE ÖLÇÜYÜ DEĞİŞTİR

Sorun modelde değil **ölçümde**: doğruluk bu dağılımda bilgi taşımıyor. Sonra sınıf ağırlığı. Çoğaltma/azaltma en son ve yalnız eğitim kümesinde.

4 • ETİKET GÜRÜLTÜLÜ

Uzmanlar arası uyum modelin **üst sınırı**; %70 uyumda daha yükseğini beklemek gerçekçi değil. Önce etiketleme kılavuzu netleşir. Bu ölçüm 5 dakika, projenin kaderi.

5 • MODELE BAŞLAMAYIN — SORUN: MEMNUNİYETİ NASIL GÖZLEMLİYORUZ?

Üç olasılık: **ölçüm var ama başka sistemde** (anket puanları — getirin) · **vekil etiket** (tekrar satın alma, şikâyet, iade — vekil olduğunu söyleyerek) · **etiketi üretmek** (anket kurmak; yavaş ama doğru hedef).
Kritik adım: vekili iş tarafıyla **birlikte** karara bağlamak — yoksa altı ay sonra "bu model memnuniyeti ölçmüyor" tartışması çıkıyor.

BÖLÜM 2

Doğru cevabın olmadığı dünya

Buraya kadar her satırın bir cevabı vardı. Şimdi **hedef sütunu yok** —
ve değerlendirme fikrinin kendisi değişiyor.

DÖRT YÖNTEM
Kümeleme · boyut indirgeme · anomali tespiti · birliktelik

AĞIRLIK KÜMELEMEDE
Üçüncü bölümde onu kendi elinizle kuracaksınız.

NEDEN GEREKİYOR

Etiketsiz veri bir engel değil, bir fırsat

Yöntem	Ne arıyor	Tipik kullanım
Kümeleme	Birbirine benzeyen satır grupları	Müşteri segmentasyonu, ürün grupları
Boyut indirgeme	Çok sütunu az sütuna sıkıştırmak	Görselleştirme, gürültü azaltma
Anomali tespiti	Çoğunluğa benzemeyen satırlar	Sahtecilik, makine arızası, veri hatası
Birliktelik kuralları	Birlikte görülen şeyler	Sepet analizi, çapraz satış

ÜÇ DURUMDA DENETİMSİZE GİDİLİR

· Etiket **yok** ve üretmek pahalı
· Soru "tahmin et" değil, "**neler var orada**"
· Denetimli bir modele **hazırlık** yapıyorsunuz

ÜÇÜNCÜSÜ ÖNEMLİ

Kümeleme çıktısı, denetimli modele **yeni bir özellik** olarak girebilir.

ORANLAR GERÇEĞİ SÖYLÜYOR

Bir şirketin verisinin çok büyük kısmı etiketsizdir: tıklamalar, metinler, görüntüler, günlük kayıtları.
Sadece denetimli öğrenme bilen biri bu verinin **çoğuna dokunamıyor**.

GÜNÜN ANA YÖNTEMİ

Kümeleme: benzeri benzerle yan yana koymak

TEK İŞİ VAR

Her satıra bir **küme numarası** veriyor: 0, 1, 2...

Aynı numarayı alanlar birbirine benziyor, farklı numaralılar benzemiyor.
Numaraların kendisinin **hiçbir anlamı yok**.

BENZERLİK = UZAKLIK

Her satır sütun sayısı kadar boyutlu bir uzayda bir nokta. Yakın noktalar = benzer müşteriler.

GERÇEK HAYATTAN — PERAKENDE SEGMENTASYONU

Pazarlama ekibi "herkese aynı e-postayı" atmaktan kurtulmak istiyor. Kimin hangi gruba girdiğini bilmiyorlar.
Kümeleme, harcama sıklığı ve tutarına göre grupları **veriden** çıkarıyor: sık-az harcayan, seyrek-çok harcayan,
bir kez alıp kaybolan... Gruplar hazır bir listeden değil, **o şirketin müşterilerinden** geliyor.

ELLE GRUPLAMADAN FARKI

"5.000 TL üstü = iyi müşteri" sizin kuralınız. Kümeleme sınırı **veriye** sorarak koyuyor.

DİKKAT

Kümeleme **her zaman** bir sonuç verir — anlamlı olup olmadığını siz söylersiniz.

EN YAYGIN KÜMELEME ALGORİTMASI

k-ortalamalar: dört adımda tekrar eden bir döngü

DÖNGÜ

1. k tane merkez rastgele yerleştirilir
2. Her nokta en yakın merkeze atanır
3. Her merkez, kendi noktalarının ortasına taşınır
4. 2 ve 3 tekrarlanır — merkezler yerinde kalana kadar

```python
from sklearn.cluster import KMeans

model = KMeans(
    n_clusters=4,
    random_state=42)

kumeler = model.fit_predict(X)
```

DÜNKÜ KALIP, KÜÇÜK BİR FARKLA

Kur, eğit, çıktı al — aynı. Ama fit çağrısına **y verilmiyor**, çünkü y yok.
fit_predict hem eğitiyor hem küme numaralarını döndürüyor.

RASTGELE BAŞLANGIÇ

Farklı başlangıç, farklı sonuç. random_state yine şart.

k'YI SİZ VERİYORSUNUZ — VE BU BİR HİPERPARAMETRE

Algoritma kaç küme olacağını bulmuyor, **söylediğiniz sayıda küme üretiyor**.
Dört derseniz dört küme çıkar — veride dört grup olmasa bile. Sıradaki slayt bu sorunu konuşuyor.

BÖLÜMÜN EN ÇOK SORULAN SORUSU

Kaç küme olmalı?

Yöntem	Nasıl çalışır	Sınırı
Dirsek yöntemi	k arttıkça küme içi dağılım düşer; düşüşün yavaşladığı yer	Dirsek her zaman net değildir
Siluet puanı	Her nokta kendi kümesine ne kadar yakın, komşuya ne kadar uzak	Tek sayıya indirger
İş kısıtı	Ekip kaç farklı kampanya yönetebilir?	En çok işe yarayan
Yorumlanabilirlik	Kümelere isim verebiliyor musunuz?	Öznel ama belirleyici

PRATİK YOL

k'yı 2'den 8'e kadar deneyin, her birinde kümelerin **profiline** bakın.
Sonra sorun: bu grupları bir pazarlama toplantısında anlatabilir miyim?
Anlatılamayan bölünme, matematiksel olarak iyi olsa da işe yaramıyor.

DÜNÜN DENGESİ, BURADA DA VAR

Çok az k: gruplar iç içe.
Çok fazla k: anlamsız parçalar.

GERÇEK HAYATTAN — ÜÇ KİŞİLİK PAZARLAMA EKİBİ

Siluet puanı yedi kümeyi işaret ediyor olabilir. Ama ekip üç farklı kampanya yönetebiliyorsa, yedi küme **kullanılamaz**. Doğru k, uygulanabilir olan k'dır.

ATLANIRSA HER ŞEY BOZULUR

Ölçekleme: büyük sayılar tartışmayı kazanır

SORUN — SOMUT ÖRNEK

İki müşteri: biri 3 kez alışveriş yapmış 12.000 TL harcamış, diğeri 5 kez alışveriş yapmış 11.800 TL harcamış.

Uzaklık hesabında **200 TL farkı**, 2 alışveriş farkını tamamen eziyor.

ÇÖZÜM

Her sütunu **aynı ölçeğe** getirmek. Sonra tüm sütunlar eşit söz hakkına sahip olur.

```
from sklearn.preprocessing import StandardScaler

olcekleyici = StandardScaler()
X_olcekli = olcekleyici.fit_transform(X)

# artık kümeleme X_olcekli üzerinde yapılır
```

İKİ YAYGIN YÖNTEM

Standart: ortalama 0, yayılım 1
Min-maks: hepsi 0 ile 1 arasına

Kümelemede genelde standart.

HANGİ YÖNTEMLER ÖLÇEKLEME İSTER

Uzaklık kullananlar ister: k-ortalamalar, en yakın komşu. · **Ağaçlar istemez:** dün kurduğumuz karar ağacı etkilenmiyor.

DÜNÜN KURALI BURADA İŞLEMİYOR

Kümeleme nasıl değerlendirilir?

NEDEN EĞİTİM-TEST AYRIMI YOK

Test kümesinde **karşılaştıracak doğru cevap yok**.

"Model bu müşteriyi küme 2'ye attı" — doğru mu? Veride cevap yazmıyor.

AMA TEKRARLANABİLİRLİK ÖLÇÜLÜR

Veriyi ikiye bölüp ayrı ayrı kümeleyin: **benzer gruplar** çıkıyor mu?

Sorulacak soru	İyi cevap neye benzer
Kümeler ayrışıyor mu?	Siluet puanı makul; profiller birbirinden belirgin farklı
Boyutlar makul mu?	Tek küme müşterilerin %95'ini tutmuyor; 3 kişilik küme yok
İsim verebiliyor muyuz?	Her kümeye bir cümlelik tanım yazılabiliyor
Tekrarlanıyor mu?	Farklı örneklemde benzer gruplar çıkıyor
Aksiyon üretiyor mu?	Her küme için farklı bir şey yapılacak

EN ZORLAYICI SORU SON SATIR

Beş kümeniz var ve hepsine aynı kampanyayı yapacaksanız, segmentasyon **işe yaramamış**.
Kümeleme başarısı, matematikte değil o kümelerle yapılan işte ölçülüyor.

İKİNCİ YÖNTEM

Boyut indirgeme: 40 sütunu 2 sütuna sıkıştırmak

NE YAPIYOR

Birbiriyle çok ilişkili sütunları **birleştirip** daha az sayıda yeni sütun üretiyor.

Bilginin çoğu korunuyor, tekrar eden kısım atılıyor.

EN ÇOK NE İÇİN

Görselleştirme. 40 boyutlu veriyi çizemezsiniz; 2 boyuta indirip **kümelerinizi** görebilirsiniz.

```
from sklearn.decomposition import PCA

pca = PCA(n_components=2)
X_2b = pca.fit_transform(X_olcekli)

plt.scatter(X_2b[:, 0], X_2b[:, 1], c=kumeler)
```

BEDELİ VAR

Yeni sütunların **adı yok**. "Bileşen 1" ne demek, iş tarafına anlatmak zor.

GERÇEK HAYATTAN — ANKET VERİSİ

Otuz soruluk bir memnuniyet anketinde sorular birbirine çok benziyor; cevaplar birlikte hareket ediyor.
Boyut indirgeme bunları birkaç **temel eğilime** indiriyor: "hizmet memnuniyeti", "fiyat algısı" gibi.

ÜÇÜNCÜ YÖNTEM

Anomali tespiti: alışılmadık olanı bulmak

MANTIĞI

Önce "normal"in neye benzediği veriden öğreniliyor.

Sonra her yeni satır soruluyor: bu, normale **ne kadar benziyor?**

NE ZAMAN BU, NE ZAMAN SINIFLANDIRMA

Geçmiş sahteciliklerin **etiketi varsa** denetimli kurun.
Yoksa anomali tespiti.

GERÇEK HAYATTAN — ÜÇ KULLANIM

Sahtecilik: kartın hiç kullanılmadığı bir ülkeden, alışılmadık saatte, alışılmadık tutarda işlem
Kestirimci bakım: titreşim ve sıcaklık değerlerinin bilinen desenden sapması
Veri kalitesi: bir sensörün ya da entegrasyonun bozulduğunu **kimse söylemeden** yakalamak

EN BÜYÜK ZORLUK

Alışılmadık olan her şey **kötü değil**. Yeni bir kampanya da anormal görünür.
Model "farklı" diyor; "kötü" demiyor.

ÜÇÜNCÜ KULLANIM

Veri kalitesi izleme, en az bilinen ve **en hızlı getirisi olan** kullanım.

DÖRDÜNCÜ YÖNTEM

Birliktelik kuralları: birlikte alınanlar

ÇIKTISI BİR CÜMLE

"Bu iki ürünü alanların büyük bölümü üçüncüyü de alıyor."

Model bir tahmin değil, bir **desen listesi** üretiyor.

NEREDE KULLANILIR

Raf düzeni, çapraz satış, menü tasarımı, kampanya paketleri.

Ölçü	Ne söylüyor	Neden tek başına yetmez
Destek	Bu birliktelik ne sıklıkta görülüyor	Nadir ama değerli desenleri gizler
Güven	A alanların kaçı B'yi de alıyor	B zaten çok satıyorsa yanıltır
Kaldıraç	Birliktelik rastlantıdan ne kadar fazla	Asıl bakılacak ölçü budur

KLASİK TUZAK — EKMEK HER SEPETTE VAR

"Zeytin alanların %80'i ekmek de alıyor" kulağa güçlü geliyor. Ama ekmeği **zaten herkes** alıyor.
Zeytin bilgisi hiçbir şey eklemiyor. Kaldıraç ölçüsü bunu yakalıyor: rastlantıya göre fazlalık yoksa kural değersiz.
Birliktelik **nedensellik de değildir** — birlikte görülmek, biri diğerine sebep oluyor demek değil.

KONTROL NOKTASI 2 • BÖLÜM 2 SONU

Dört yöntemi dört probleme eşleyin

HANGİ YÖNTEM — 10 DAKİKA, İKİLİ

a) 10.000 müşteriye kaç farklı kampanya kurgulayalım?
b) Gece 3'te 40.000 TL'lik kart işlemi — normal mi?
c) 60 sütunlu veriyi bir grafikte göstermek istiyoruz
d) Hangi ürünleri yan yana rafa koyalım?
e) Bu abone önümüzdeki ay ayrılacak mı?

BİRİ TUZAK

Beş sorudan biri **denetimsiz değil**.

Hangisi ve neden?

Gerekçesini bir cümleyle yazın.

İKİNCİSİ TARTIŞMALI

(b) için **iki farklı cevap** doğru olabilir. Hangi koşulda hangisi?

EK SORU

(a) için **kaç küme** seçerdiniz? Hangi bilgiye bakarak?

Mola, sonra bölüm 3: **kendi segmentasyonunuzu** kuruyoruz. Notebook açık olsun.

BÖLÜM 2 • KISA SINAV

Kümeleme üzerine beş soru

1

Kümeleme sonucunda bir kümede müşterilerin %96'sı var. Ne olmuş olabilir?

2

Küme 3'ün müşterileri küme 1'den "daha iyi" mi? Numaralar ne anlama geliyor?

3

Siluet puanı k=7'yi işaret ediyor, pazarlama 3 kampanya yönetebiliyor. Kararınız?

4

Aynı kodu iki kez çalıştırdınız, segmentler farklı çıktı. Sebebi ve çözümü?

5 • EN ZORU

Bir danışman geldi: "Müşterilerinizi 5 segmente ayırdık, siluet puanı yüksek, sonuç çok başarılı."
Hangi üç soruyu sorarsınız?

BÖLÜM 2 • CEVAPLAR

Kümeleme üzerine beş soru

1 • ÖNCE ÖLÇEKLEMEYE BAKIN

Büyük ölçekli bir sütun her şeyi belirliyor olabilir. Sonra **aykırı değerler**: birkaç uç müşteri kendi kümesini alıyor. Üçüncüsü: veride gerçekten grup yapısı yok — bu da bir sonuç.

2 • NUMARA SADECE ETİKET

Sıralama ya da değer taşımıyor; farklı rastgele başlangıçta aynı grup başka numara alıyor. O yüzden kümelere **isim** verilir — raporda "küme 3" altı ay sonra okunmuyor.

3 • ÜÇ KÜME İLE GİDİN

Siluet matematiksel gösterge, kapasite **kısıt**; uygulanamayan bölünme değer üretmiyor. Zarif yol: 7 kümeyi bulup iş mantığıyla 3 gruba birleştirmek.

4 • RASTGELE BAŞLANGIÇ

Çözüm random_state. Ama derin soru şu: fark ciddiyse veride **güçlü küme yapısı olmayabilir**. Veriyi ikiye bölüp ayrı kümeleyin — benzer gruplar çıkmıyorsa güvenmeyin.

5 • ÜÇ SORU — SİLUET PUANI TEK BAŞINA BİR ŞEY SÖYLEMİYOR

1 Her segment için ne yapacağız, hangi segmente hangi aksiyon? · **2** Boyutlar ne, hangi sütunlarla kuruldu, ölçekleme yapıldı mı? **3** Tekrarlanabilir mi — farklı dönemde benzer gruplar çıkıyor mu? · **Dördüncüsü de yerinde:** her segmenti bir cümleyle tanımlayabiliyor musunuz?

BÖLÜM 3 • 90 DAKİKA • UYGULAMALI

Müşteri segmentasyonu, uçtan uca

Beş adım: veri hazırlığı, ölçekleme, kümeleme, kümeleri okuma, **isimlendirme**.
Son adım teknik değil — ve işin değerinin çıktığı yer o.

BİRLİKTE YAZACAĞIZ
Her hücreyi siz de çalıştırın; sonunda tam akış elinizde olacak.

AYNI SİPARİŞ VERİSİ
Ama bu kez satır başına **müşteri**, sipariş değil.

KODA BAŞLAMADAN ÖNCE

İş problemi: kime ne söyleyeceğiz?

BUGÜNKÜ SENARYO

Pazarlama ekibi şu an **herkese aynı** e-postayı atıyor.

İstek: müşterileri birbirinden anlamlı şekilde farklı gruplara ayırmak ve her gruba **kendi mesajını** göndermek.

KISIT

Ekip en fazla **dört** farklı kampanya kurgulayabiliyor.

Yani k en çok 4.

Karar	Seçimimiz	Gerekçe
Satır nedir	Bir müşteri	Segment müşteriye verilecek, siparişe değil
Hangi sütunlar	Sıklık, toplam tutar, son alışveriş	Pazarlama kararını bu üçü etkiliyor
Kapsam	En az 1 siparişi olanlar	Hiç almayan için segment anlamsız

BU SLAYT NEDEN ÖNCE GELİYOR

Önce koda başlayıp sonra "ne yapıyorduk" diye sormak, en sık görülen ve **en pahalı** proje hatası.

ÜÇ SÜTUNUN ADI VAR

RFM: ne zaman, ne sıklıkta, ne kadar

Boyut	Nasıl hesaplanır	Ne söylüyor
Yakınlık (Recency)	Bugün – son sipariş tarihi	Müşteri hâlâ bizimle mi, uzaklaşıyor mu
Sıklık (Frequency)	Sipariş sayısı	Alışkanlık kurmuş mu, tek seferlik mi
Tutar (Monetary)	Toplam harcama	Ticari değeri ne

NEDEN BU ÜÇÜ

· Her şirkette **hesaplanabiliyor** — sipariş tablosu yeterli
· Üçü birlikte farklı müşteri tiplerini ayırabiliyor
· Yorumlanabiliyor: pazarlama ekibi üçünü de anlıyor
· Doğrudan aksiyona bağlanıyor

ÜÇ BOYUT YETER Mİ

Başlangıç için evet. Sonra kategori çeşitliliği, iade oranı, kanal gibi boyutlar eklenir.

YAKINLIKTA TERS MANTIK — DİKKAT

Yakınlık **gün sayısı** olarak hesaplanıyor: küçük sayı iyi, büyük sayı kötü.
Diğer ikisinde tam tersi. Kümeleri okurken bunu karıştırmak çok sık yapılan bir hata.

ADIM 1 / 5

Sipariş tablosunu müşteri tablosuna çevirmek

```python
import pandas as pd

df = pd.read_csv("siparisler.csv", parse_dates=["tarih"])
bugun = df["tarih"].max()

musteri = df.groupby("musteri_id").agg(
    yakinlik=("tarih", lambda s: (bugun - s.max()).days),
    siklik=("siparis_id", "count"),
    tutar=("net_tutar", "sum"))
```

İLK KONTROL — ATLAMAYIN

musteri.describe() yazın: kaç müşteri var, üç sütunun aralıkları ne? Tutarın en büyüğü ortalamanın 50 katıysa **aykırı değer** var.

GEÇEN HAFTANIN BİLGİSİ

groupby ve agg — yeni bir şey yok, sadece yeni bir amaç.

"BUGÜN" NEREDEN

Gerçek tarih değil, **verinin en son günü**. Yoksa herkes eski görünür.

AYKIRI DEĞER NE YAPAR

Kendine bir küme açar; geri kalan herkes **tek kümede** toplanır.

AYKIRI DEĞERLE NE YAPILIR

Silmeyin — onlar muhtemelen **en değerli müşteriler**. Ayrı bir liste olarak çıkarıp elle yönetin.

ADIM 2 / 5

Üç sütunu eşit söz hakkına getirmek

```
from sklearn.preprocessing import StandardScaler

X = musteri[["yakinlik", "siklik", "tutar"]]

olcekleyici = StandardScaler()
X_olcekli = olcekleyici.fit_transform(X)
```

ÖLÇEKLEMESEYDİK

Tutar binlerle, sıklık birlerle. Kümeleme **sadece tutara** göre yapılırdı.

Sonuç: bir harcama sıralaması, segmentasyon değil.

DENEYİN — EN ÖĞRETİCİ ADIM

Kümelemeyi bir kez **X** ile, bir kez **X_olcekli** ile çalıştırın.
İki sonucu yan yana koyun. Fark, ölçeklemeyi bir daha asla atlatmıyor.

SAKLAYIN

Ölçekleyiciyi atmayın: yeni müşterileri de **aynı** dönüşümden geçirmeniz gerekecek.

BİR AYRINTI — ÇARPIK DAĞILIM

Harcama gibi sütunlarda birkaç müşteri çok yüksek, çoğu düşük olur. Ölçekleme bunu **düzeltmiyor**, sadece kaydırıyor.
Böyle sütunlarda logaritma dönüşümü yardımcı olabiliyor — Gün 4'ün konusu.

ADIM 3 / 5

k'yı deneyerek kümelemek

```
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score

for k in [2, 3, 4]:
    m = KMeans(n_clusters=k, random_state=42, n_init=10)
    etiket = m.fit_predict(X_olcekli)
    print(k, silhouette_score(X_olcekli, etiket).round(3))
```

n_init NEDİR

Farklı başlangıçlarla **10 kez** dener, en iyisini tutar. Rastgeleliğe karşı sigorta.

SİLUET PUANINA

bakın ama **tek başına** karar vermeyin.

KARAR NASIL VERİLİR — ÜÇ GÖSTERGEYE BİRLİKTE BAKIN

1. Siluet puanı makul mu · **2.** Küme boyutları dengeli mi · **3.** Profillere isim verebiliyor musunuz
Üçü uyuşuyorsa karar nettir. Uyuşmuyorsa **üçüncüsü** kazanır.

KÜME BOYUTLARINI MUTLAKA YAZDIRIN

pd.Series(etiket).value_counts() — bir küme herkesi tutuyorsa bir şey ters gitmiş.

ADIM 4 / 5

Kümelerin içine bakmak: profil tablosu

```
musteri["kume"] = etiket

profil = musteri.groupby("kume").agg(
    kisi=("tutar", "size"),
    yakinlik=("yakinlik", "median"),
    siklik=("siklik", "median"),
    tutar=("tutar", "median"))
```

NEDEN ORTALAMA DEĞİL MEDYAN

Tek bir büyük müşteri ortalamayı sürüklüyor. Medyan **tipik müşteriyi** gösteriyor.

Küme	Kişi	Yakınlık (gün)	Sıklık	Tutar (TL)
0	2.140	18	7	9.400
1	3.880	24	2	1.250
2	1.460	186	4	5.700
3	2.620	142	1	680

BU TABLO ÖRNEKTİR — SİZDE BAŞKA SAYILAR ÇIKACAK

Önemli olan sayılar değil, **okuma biçimi**: her kümeyi diğerleriyle karşılaştırın, hangi boyutta yüksek hangi boyutta düşük olduğunu bulun. İsim bu karşılaştırmadan çıkıyor.

ADIM 5 / 5 • TEKNİK OLMAYAN ADIM

Numaradan isme: işin değeri burada

Küme	İsim	Tek cümlelik tanım	Önceliği
0	Sadık çekirdek	Yakın zamanda, sık ve çok alan grup	Korumak — kaybı pahalı
1	Yeni tanışanlar	Yeni gelmiş, henüz alışkanlık kurmamış	Büyütmek — ikinci siparişe taşımak
2	Uzaklaşan değerliler	Geçmişte iyi müşteriydi, görünmez oldu	En acil — geri kazanım
3	Tek seferlikler	Bir kez aldı, dönmedi	Düşük — maliyeti kontrol et

İYİ İSMİN ÜÇ ÖZELLİĞİ

- **Davranışı** anlatıyor, puanı değil — "uzaklaşan", "A segmenti" değil
- Toplantıda **açıklama gerektirmiyor**
- Bir aksiyonu **çağırıyor**: korumak, büyütmek, geri kazanmak

İSİM VEREMEZSENİZ

Bu bir **bulgu**: k yanlış seçilmiş ya da sütunlar ayırt etmiyor. Geri dönün.

İSİMLENDİRMEYİ YALNIZ YAPMAYIN

Profil tablosunu pazarlama ekibine götürün: isimleri **onlar** koysun. Sahiplenme böyle oluşuyor.

SEGMENTASYONUN GERÇEK ÇIKTISI

Her segmente ne yapacağız?

Segment	Aksiyon	Başarı nasıl ölçülür
Sadık çekirdek	İndirim yok; erken erişim, sadakat ayrıcalığı	Bu grupta kayıp oranı artmıyor mu
Yeni tanışanlar	İkinci siparişi tetikleyen ilgili ürün önerisi	İkinci sipariş oranı yükseliyor mu
Uzaklaşan değerliler	Kişisel geri dönüş teklifi, belki arama	Kaçı geri döndü, ne harcadı
Tek seferlikler	Düşük maliyetli otomatik hatırlatma	Dönüş oranı maliyeti karşılıyor mu

EN ÖNEMLİ SATIR BİRİNCİSİ

Sadık müşteriye indirim yapmak, zaten alacağı şeye **para ödemek**.
Segmentasyonun ilk getirisi genelde **boşa giden indirimi durdurmak** oluyor.

KONTROL GRUBU

Her segmentin küçük bir kısmına **hiçbir şey yapmayın**. Farkı ancak böyle ölçersiniz.

SEGMENTLER DONDURULMUŞ DEĞİL

Müşteriler segment değiştiriyor. Düzenli olarak yeniden hesaplayın ve **geçişleri izleyin** — asıl bilgi orada.

TEK SLAYTTA TÜM AKIŞ • NOT ALIN

Segmentasyon iskeleti

```python
import pandas as pd
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans

df = pd.read_csv("siparisler.csv", parse_dates=["tarih"])
bugun = df["tarih"].max()

m = df.groupby("musteri_id").agg(
    yakinlik=("tarih", lambda s: (bugun - s.max()).days),
    siklik=("siparis_id", "count"),
    tutar=("net_tutar", "sum"))

X = StandardScaler().fit_transform(m)
m["kume"] = KMeans(4, random_state=42, n_init=10).fit_predict(X)

print(m.groupby("kume").median(), m["kume"].value_counts())
```

BEŞ ADIM

1. Müşteri bazına indir
2. Ölçekle
3. Kümele (k'yı dene)
4. Profili oku
5. İsim ver, aksiyona bağla

DÜNKÜ AKIŞLA FARK

- **y yok**
- Eğitim-test ayrımı yok
- Ölçekleme **zorunlu**
- Son adım insan işi

ON BEŞ SATIR, SATILABİLİR BİR ÇIKTI

Zor olan kod değil: **doğru sütunları seçmek, kümeleri okumak ve iş diline çevirmek**.

KONTROL NOKTASI 3 • BÖLÜM 3 SONU

Kendi segmentasyonunuzu bitirin

BEŞ GÖREV — 25 DAKİKA

1. Tam akışı çalıştırın, profil tablosunu çıkarın.
2. k=3 ve k=4 için profilleri karşılaştırın. Hangisi anlatılabilir?
3. Seçtiğiniz k için **her kümeye isim** ve bir cümlelik tanım yazın.
4. Her isme bir **aksiyon** yazın.
5. Ölçekleme satırını kaldırıp çalıştırın. Küme boyutları ne oldu?

ASIL İŞ 3 VE 4

Kod bir dakikada çalışır.

İsim ve aksiyon yazmak **düşünmek** gerektiriyor — zamanın çoğunu oraya verin.

TAKILIRSANIZ

Profili okurken her boyutta "**diğerlerine göre** yüksek mi düşük mü" diye sorun.

BİTİRENLER İÇİN

Dördüncü bir boyut ekleyin: **ortalama sepet** veya **iade oranı**. Ne değişti?

Sonuçları paylaşacağız, sonra bölüm 4: **hangi aileyi ne zaman** seçmeli.

BÖLÜM 3 • KISA SINAV

Uygulamanın içinden beş soru

1

Yakınlık için neden gerçek bugünün tarihini değil, verinin son gününü kullandık?

2

Profil tablosunda neden ortalama değil medyan kullandık?

3

Yarın yeni bir müşteri geldi. Onu bir segmente atamak için ne gerekiyor?

4

Segmentasyonu kurdunuz. Pazarlama "hepsine aynı kampanyayı yapalım" dedi. Cevabınız?

5 • EN ZORU

"Uzaklaşan değerliler" segmentine geri kazanım kampanyası yaptınız. Üç ay sonra o segment **küçüldü**.
Kampanya başarılı mı?

BÖLÜM 3 • CEVAPLAR

Uygulamanın içinden beş soru

1 • VERİ ANLIK GÖRÜNTÜ

Veri üç ay önce bitiyorsa **en aktif müşteri bile 90 gün uzakta** görünür; yakınlık ayırt etme gücünü kaybeder. Canlıda referans gerçek bugün olur — o zaman verinin güncel aktığından emin olun.

2 • DAĞILIM ÇARPIK

Tek kurumsal müşteri, ortalamayı **kimsenin harcamadığı** seviyeye çekiyor. Medyan ortadaki kişiyi gösteriyor. İkisini birlikte bakın: büyük fark, aykırı değer işareti.

3 • ÜÇ ŞEY GEREKİYOR

Yakınlık-sıklık-tutarı hesapla → **eğitimde kullanılan aynı ölçekleyiciden** geçir (yenisini eğitmek yanlış) → predict ile en yakın merkez. Yani ikisini de saklamak gerekiyor.

4 • O ZAMAN GEREK YOK

Değer farklı gruba farklı davranmaktan geliyor. Ama arkasında gerçek kısıt var: **iki kampanyayla başlayın** — en değerli ikisine özel, kalanlara standart.

5 • SEGMENTİN BOYUTU CEVAP VERMİYOR — GEÇİŞLERE BAKIN

Segment iki şekilde küçülüyor: **geri döndüler** ve aktif segmente geçtiler, ya da **daha da uzaklaştılar** ve kapsam dışına çıktılar. Doğru ölçüm: o müşteriler hangi segmente gitti? Bunun için eski atamalar saklanmış olmalı. Ve **kontrol grubu**: kampanya gitmeyen benzer müşteriler ne yaptı?

BÖLÜM 4

Hangisini, ne zaman

İki aileyi ayrı ayrı gördük. Gerçek projelerde soru "hangisi" değil, çoğu zaman **ikisini nasıl birlikte kullanacağım**.

KARAR REHBERİ
Dört soruyla doğru aileye gidiyorsunuz.

AZ ETİKETLE ÇALIŞMAK
Bölüm 1'de söz verdiğimiz konu burada.

KARAR REHBERİ • NOT ALIN

Dört soru, doğru aile

#	Soru	Evet ise	Hayır ise
1	Tahmin etmek istediğim şeyin geçmiş cevabı veride var mı?	Denetimli	2. soruya geç
2	Etiketi makul maliyetle üretebilir miyim?	Üret, sonra denetimli	3. soruya geç
3	Sorum "bunu tahmin et" mi, "orada neler var" mı?	Keşif ise denetimsiz	4. soruya geç
4	Aradığım şey nadir ve tanımı belirsiz mi?	Anomali tespiti	Problemi yeniden kurun

İKİNCİ SORU EN ÇOK ATLANAN

"Etiket yok" cevabı çoğu zaman **"etiket henüz üretilmedi"** demek.
Bin örneği elle etiketlemek bir haftalık iş olabilir ve denetimli bir modelin kapısını açar.
Hemen denetimsize kaçmayın.

DÖRDÜNCÜ SATIRIN SONU

Hiçbirine uymuyorsa sorun yöntemde değil, **soruda**.

BİR ÖNCELİK KURALI

Mümkünse **denetimli** tercih edin: ölçülebilir, savunulabilir, iyileştirilebilir.
Denetimsiz güçlü ama başarısı tartışmaya açık — dün ve bugün gördüğünüz fark bu.

GERÇEK PROJELERİN DESENİ

İkisini birlikte kullanmanın dört yolu

Desen	Nasıl	Örnek
Küme = yeni özellik	Segment numarasını denetimli modele sütun olarak ver	Kayıp tahmininde segment bilgisi
Segment başına model	Her segment için ayrı bir denetimli model kur	Kurumsal ve bireysel için ayrı tahmin
Keşif → hedef	Kümeleme hangi problemin değerli olduğunu gösterir	Büyük bir riskli grubu fark etmek
Boyut indirgeme → model	Çok sütunlu veriyi sıkıştırıp modele ver	Yüzlerce sütunlu anket verisi

İKİNCİ DESEN NE ZAMAN İŞE YARAR

Gruplar **farklı mantıkla** davranıyorsa. Kurumsal müşterinin iade sebebi ile bireysel müşterinin iade sebebi aynı değil; tek model ikisinin ortalamasını öğreniyor.

BEDELİ

Her segmentte **yeterli veri** olmalı. Beş model kurup hepsini zayıf bırakmak kolay.

ÖNCE BASİT OLANI DENEYİN

Birinci desen tek satırlık iş ve çoğu zaman yeterli. İkinci desen bir mimari karar, operasyonel yükü var: **beş model beş kez bakım** demek.

ARADA KALAN DURUM

Biraz etiket var, çoğu yok

EN YAYGIN GERÇEK DURUM

Elinizde 500 etiketli, 200.000 etiketsiz satır var.

Denetimli için az, denetimsize geçmek ise **o 500'ü çöpe atmak**.

ADI

Yarı denetimli öğrenme.

İkisinin arasında duran bir yaklaşım ailesi.

Yaklaşım	Fikri	Riski
Kümele, sonra etiketle	Her kümeden birkaç örneği etiketleyip kümeye yay	Küme homojen değilse yanlış yayılır
Kendi kendine etiketleme	Model çok emin olduğu satırları kendi etiketler	Kendi hatasını pekiştirir
Etkin öğrenme	Modelin en kararsız kaldığı örnekleri uzmana sor	Döngü kurmak emek ister

ÜÇÜNCÜSÜ EN VERİMLİSİ — VE EN AZ BİLİNENİ

Rastgele bin örnek etiketlemek yerine, modelin kararsız kaldığı iki yüz örneği etiketleyin.
Aynı uzman zamanıyla **daha iyi bir model** çıkıyor, çünkü öğrenilecek bilgi sınır vakalarda.
Üretim bandı örneğini hatırlayın: proje uzmanın takvimiyle sınırlıydı — bu yöntem o takvimi verimli kullanıyor.

PRATİK BİLGİ

Etiket yoksa nasıl üretilir?

Yol	Nasıl	Dikkat
Geçmişten türetmek	Sonucu zaten olmuş olaylardan etiket çıkarmak	Pencere tanımını yazılı yapın
Vekil etiket	İstediğinizin yerine onunla ilişkili bir şeyi ölçmek	Vekil olduğunu açıkça söyleyin
Davranış izi	Tıklama, iptal, iade, şikâyet gibi kayıtlar	Davranış niyeti tam yansıtmıyor
Elle etiketleme	Uzmanın örnekleri tek tek işaretlemesi	Kılavuz yazın, uyumu ölçün
Ölçüm kurmak	Bugünden itibaren etiket toplamaya başlamak	Yavaş ama en doğru yol

GERÇEK HAYATTAN — VEKİL ETİKET

"Müşteri memnuniyeti" ölçülmüyor ama **tekrar satın alma** veride var. Memnuniyetin kendisi değil; ama onunla ilişkili ve bugün elinizde.

VEKİLİN RİSKİ

Model vekili tahmin ediyor, asıl şeyi değil. Altı ay sonra bu **unutuluyor**.

EN SON YOLU KÜÇÜMSEMEYİN

Bugün ölçüm kurarsanız **altı ay sonra** doğru etiketli bir veri setiniz olur. Çoğu şirket bunu hiç başlatmıyor.

YEDİ SEKTÖR, YEDİ KARAR

Karar rehberi, sahada

Sektör	Soru	Aile	Neden
Perakende	Müşterilerimizi nasıl gruplayalım?	Denetimsiz	Keşif sorusu, hedef yok
Telekom	Kim hattını kapatacak?	Denetimli	İptal kaydı etiket veriyor
Bankacılık	Bu işlem sahte mi?	İkisi birlikte	Kısmi etiket var
Üretim	Bu parça hatalı mı?	Denetimli (etiket üret)	Uzman etiketlemesi gerekiyor
Lojistik	Bu sevkiyat gecikir mi?	Denetimli	Geçmiş teslim süreleri var
Sağlık	Hasta grupları nasıl ayrışıyor?	Denetimsiz	Keşif ve hipotez üretme
E-ticaret	Hangi ürünler birlikte alınıyor?	Birliktelik kuralları	Tahmin değil, desen

ÜÇÜNCÜ SATIR GERÇEK HAYATIN ÖZETİ

Yakalanmış sahtecilikler etiketli, **yakalanmamışlar değil**. Denetimli model bilineni yakalar,
anomali tespiti yeni yöntemleri fark eder. İkisi birlikte çalışıyor.

ALTINCI SATIR

Keşif çıktısı bir **hipotez**; klinik doğrulama ayrı iştir.

SORULARIN DİLİNE DİKKAT

"Nasıl gruplayalım" ve "nasıl ayrışıyor" keşif; "kim", "olur mu", "ne kadar" **tahmin**.

BUGÜNÜN HATA LİSTESİ

Sekiz sık hata ve panzehiri

Hata	Panzehir
Etiketin tanımını yazmadan başlamak	Bir sayfa yaz, iş tarafına onaylat
Tahmin anında olmayan sütunu özellik yapmak	"Bu bilgi o saniyede var mıydı?" testi
Kümelemeden önce ölçeklememek	Uzaklık kullanan her yöntemde ölçekle
Dengelemeyi bölmeden önce yapmak	Önce böl, sonra sadece eğitimi dengele
k'yı sadece siluet puanıyla seçmek	Boyut + yorumlanabilirlik + iş kısıtı
Kümelere numara ile hitap etmek	İsim ver, tanım yaz, aksiyona bağla
Vekil etiketi asıl etiket sanmak	Modeli ne tahmin ettiğine göre adlandır
Segmentleri bir kez kurup unutmak	Düzenli yenile, geçişleri izle

BU LİSTENİN ORTAK YANI

Sekizinin de sebebi algoritma bilgisi eksikliği değil.
Hepsi **süreç** hatası: bir adımı atlamak, bir soruyu sormamak, bir şeyi yazmamak.

ÖNERİ

Bu tabloyu bir **kontrol listesi** olarak saklayın; her projede baştan okuyun.

KONTROL NOKTASI 4 • BÖLÜM 4 SONU

Kendi probleminizi karar rehberinden geçirin

DÖRT SATIR — 12 DAKİKA

1. **Probleminiz:** _____
2. **Hangi aile (dört soruyu uygulayın):** _____
3. **Etiket durumu:** var / üretilebilir / yok
4. **İlk adım (bu hafta yapılacak):** _____

DÖRDÜNCÜ SATIR ÖNEMLİ

"Model kurmak" bir ilk adım **değil**.

Veriye bakmak, etiketi sormak, tanımı yazmak — bunlar ilk adım.

İKİ GÜNÜN BİRLEŞİMİ

Dün kontrol noktası 3'te veriyi tanımladınız; bugün **yaklaşımı** seçiyorsunuz.

ÜÇ KİŞİ ANLATSIN

Mümkünse **farklı sektörlerden** — transfer en çok böyle oluyor.

Sonra günü kapatıyoruz. Yarın: **model geliştirme ve özellik seçimi**.

BÖLÜM 4 • KISA SINAV

Hangi yaklaşım — beş durum

1

"Etiketimiz yok, kümeleme yapalım" diyen bir ekibe hangi soruyu sorarsınız?

2

Kurumsal ve bireysel müşteriler çok farklı davranıyor. Tek model mi, iki model mi?

3

Etiketleme bütçeniz 500 örnek. Hangi 500 örneği uzmana gönderirsiniz?

4

Bugünkü segment numarasını yarınki kayıp tahmini modeline nasıl verirsiniz?

5 • EN ZORU

Yönetim "yapay zekâ ile müşterilerimizi daha iyi tanıyalım" diyor. Başka hiçbir şey söylemiyor.
İlk hafta ne yaparsınız?

BÖLÜM 4 • CEVAPLAR

Hangi yaklaşım — beş durum

1 • "GERÇEKTEN YOK MU?"

Yoksa **henüz üretilmedi mi?** Sistemde sonuç kaydı (iptal, iade, ödeme), davranış izi vekil olarak, ya da 1.000 örnek elle. Kümeleme meşru ama varsayılan seçim olmamalı.

2 • ÖNCE TEK MODEL

Müşteri tipini **bir özellik olarak** verin — tek satır, çoğu zaman yeterli. Ayrı model iki koşulla: farklı mantık **ve** her grupta yeterli veri. Kurumsal azsa ikincisi sağlanmıyor.

3 • EN KARARSIZ 500

Rastgele değil — **etkin öğrenme**. Model emin olduğu örnekten yeni bilgi çıkmıyor; sınır vakalar öğrenilecek yer. Nadir sınıfı kaçırmamak için bir miktar rastgele de karıştırın.

4 • SÜTUN OLARAK, AMA

Segment **kategori**, sayı değil (Gün 4'te kodlama). Kritik olan: segmenti bugünkü veriyle hesaplayıp geçmişi tahmin etmek **sızıntıdır** — tahmin anından önceki veriyle hesaplanır.

5 • KODA BAŞLAMAYIN — İLK HAFTA ÜÇ İŞ

1 Soruyu daralt: "daha iyi tanımak" ne işe yarayacak — kampanya, kayıp önleme, fiyatlandırma? Her biri farklı problem ve farklı aile.
2 Veriyi gör: hangi tablolar, kaç müşteri, hangi sütunlar dolu, hangi sonuç kayıtları tutuluyor. · **3 Kim ne yapacak:** çıktıyı kullanacak ekip, kaç farklı aksiyon yönetebiliyor?

GÜNÜN ÖZETİ

Bugün elinize ne geçti

Bölüm	Ana fikir	Akılda kalması gereken cümle
1 · Denetimli	Etiketin kaynağı modeli belirler	Bu etiket nereden geldi, kim hangi tanımla koydu?
2 · Denetimsiz	Doğru cevap yoksa başarıyı iş tanımlar	Kümeleme her zaman sonuç verir; anlamlı mı, siz söylersiniz
3 · Uygulama	Beş adım: indir, ölçekle, kümele, oku, isimlendir	Numara değil isim; isim verilemiyorsa geri dönün
4 · Seçim	Dört soruyla doğru aileye gidilir	"Etiket yok" çoğu zaman "etiket henüz üretilmedi" demek

ŞİMDİ YAPABİLDİKLERİNİZ

· Bir etiketin güvenilir olup olmadığını sorgulamak
· Dengesiz sınıfta doğruluk oranına kanmamak
· k-ortalamalar ile uçtan uca segmentasyon kurmak
· Kümeleri iş diline çevirip aksiyona bağlamak
· Bir probleme bakıp hangi aileyle başlayacağınızı söylemek

HENÜZ YAPAMADIKLARINIZ

· Hangi özelliğin işe yaradığını ölçmek
· Yeni özellik üretmek
· Metin sütunlarını modele sokmak

Üçü de yarının konusu.

GÜNÜN TEK CÜMLESİ

Denetimli öğrenmede soru **"etiket nereden geliyor"**, denetimsizde **"bu bölünmeyle ne yapacağız"**.

Yarın: özellik ve hedef değişken

YARIN NE VAR • 19.10, 4 SAAT

X'in içini dolduruyoruz: hangi sütun özellik olur, hangisi zarar verir, yeni özellik nasıl üretilir.

AKŞAM İÇİN

Kontrol noktası 3'te dördüncü boyutu eklemediyseniz deneyin: kümeler nasıl değişti?

Soru biriktirmeyin — yarın ilk on dakikayı bugünün sorularına ayıracağız.